



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Tarea 1

Introducción a la Ciencia de Datos

Edición 2026

Integrantes:

Tomás Alejo Spoturno Gonzalez, 5.165.789-6

Nicolás Buero, 5.000.105-4

Universidad de la República
Facultad de Ingeniería

Mayo 2026

Índice

1. Introducción	2
2. Parte 1: Cargado y Limpieza de Datos	2
2.1. A. Exploración de datos y selección de los 5 medios principales	2
2.2. B. Visualización temporal	3
2.3. C. Limpieza de texto: <code>clean_text</code>	5
2.4. D. Elección del campo de texto a utilizar	6
2.5. E. Pistas que identifican al medio de prensa	7
2.6. F. Restricción por sección temática o período temporal	9
3. Parte 2: Conteo de palabras y visualizaciones	11
3.1. A. Palabras más frecuentes por medio	11
3.2. B. Medios con mayor cantidad de palabras	13
3.3. C. Matriz de menciones entre medios	14
3.4. D. Preguntas propuestas	15

1. Introducción

Este informe documenta la resolución de la Tarea 1 del curso *Introducción a la Ciencia de Datos* (edición 2026). El trabajo se realiza sobre un subconjunto muestreado del dataset abierto *All the News 2.1 – Component One*, que contiene artículos de noticias publicados en distintos medios de prensa. El objetivo de esta primera entrega es **cargar, explorar y limpiar** los datos, con vistas a una futura tarea de clasificación automática de textos por medio de prensa.

El código que genera los resultados, tablas y figuras está en el notebook `Tarea_1/2026_tarea1.ipynb` del repositorio público <https://github.com/Nicolasvb23/intro-cd>.

2. Parte 1: Cargado y Limpieza de Datos

2.1. A. Exploración de datos y selección de los 5 medios principales

Composición del DataFrame

El DataFrame tiene 30.213 filas (una por artículo) y 12 columnas: el contenido textual (`title`, `article`), metadatos del artículo (`publication`, `author`, `date`, `section`, `url`), los componentes desglosados de la fecha (`year`, `month`, `day`) y dos columnas de índice (`idx`, `article_idx`).

Datos faltantes por columna

Se evaluó la cantidad de valores nulos en cada columna. La Tabla 1 resume las columnas con datos faltantes.

Cuadro 1: Columnas con datos faltantes en el DataFrame.

Columna	Faltantes	%
<code>author</code>	11.405	37.75 %
<code>section</code>	10.232	33.87 %
<code>article</code>	1.176	3.89 %
<code>url</code>	141	0.47 %
<code>publication</code>	141	0.47 %

Las columnas con datos faltantes más significativos son `section` y `author`: ambas tienen una proporción alta de valores nulos. `section` no está disponible para todos los medios (por ejemplo, *The Hill* no la reporta), y `author` puede faltar en cables de agencia o en notas sin firma. El resto de los campos críticos (`publication`, `date`, `title`, `article`) están prácticamente completos.

Otros problemas de calidad

Además de los faltantes, se identificaron los siguientes problemas mediante chequeos manuales:

- **Redundancia entre `idx` y `article_idx`:** la diferencia entre ambas columnas es cero en todas las filas, es decir, contienen exactamente el mismo valor en cada registro. Una de las dos es redundante.

- **Formato heterogéneo en date:** conviven los formatos YYYY-MM-DD y YYYY-MM-DD HH:MM:SS en distintas filas. Esto obliga a usar `format='mixed'` al parsear.
- **Tipo de month:** la columna `month` se almacena como cadena de texto (`str`), no como entero, a pesar de contener únicamente valores numéricos del 1 al 12. Lo mismo ocurre con `year` y `day`. Conviene convertirlas a entero si se las quisiera utilizar para operaciones numéricas, aunque como se discute más abajo son redundantes con `date`.
- **Redundancia entre date y year, month, day:** las tres últimas son derivables exactamente de `date`. Se verificó consistencia (año, mes y día coinciden con el `date` parseado en todos los registros donde ambos existen). Por lo tanto pueden eliminarse sin pérdida de información.
- **URLs:** de las 30.072 URLs presentes, las 30.072 son válidas según un chequeo regex (esquema `http/https` y caracteres válidos). No se encontraron URLs con formato inválido en el corpus.

Selección de los 5 medios principales

El dataset contiene artículos de 26 medios de prensa, con una distribución muy desbalanceada. Para el resto del análisis se trabaja con los **cinco medios con mayor cantidad de artículos**, cuyos conteos se muestran en la Tabla 2.

Cuadro 2: Top 5 medios con mayor cantidad de artículos en el dataset.

Medio	Artículos	% del total
Reuters	9.431	31.2 %
The New York Times	2.840	9.4 %
CNBC	2.623	8.7 %
The Hill	2.349	7.8 %
People	1.528	5.1 %
Total top 5	18.771	62.1 %

A partir de este punto, todos los análisis se realizan sobre el sub-DataFrame `df_top_5`, que contiene 18.771 artículos.

2.2. B. Visualización temporal

Para visualizar la actividad de los cinco medios a lo largo del tiempo, se generó primero una serie por mes y otra por año (ver Figura 1).




Figura 1: Cantidad de artículos publicados por los 5 medios a lo largo del tiempo (granularidad mes y año).

Observaciones generales. Los cinco medios cubren aproximadamente el mismo período (de 2016-01-01 a 2020-04-01), aunque con volúmenes muy distintos. *Reuters* domina ampliamente en cantidad de artículos publicados por mes, con un nivel varias veces superior al resto. Le siguen, en un escalón intermedio similar entre sí, *NYT*, *CNBC* y *The Hill*; *People* aparece como el medio con menor volumen mensual. La cobertura es relativamente uniforme a lo largo de los años, sin saltos abruptos que sugieran cortes en la ingesta del dataset, más allá de la caída natural en el extremo derecho de la serie por el corte en abril de 2020 (el dataset finaliza ese mes y por eso 2020 muestra menos artículos acumulados que los años completos previos).

Para detectar patrones cíclicos más finos, se calculó el promedio de artículos por día de la semana y por mes del año (Figura 2).




Figura 2: Promedio de artículos por día de la semana y por mes del año.

Patrones cíclicos.

- En los **días de la semana** se observa una caída clara los sábados y domingos en los medios de tipo agencia y política (*Reuters*, *The Hill*, *CNBC*, *NYT*). *People*, en cambio, publica de forma más pareja durante toda la semana, lo que tiene sentido porque su agenda (celebrities, entretenimiento) no depende del calendario laboral.
- Por **mes del año** no hay un patrón estacional tan marcado: los medios cubren noticias de forma continua durante todo el año.

Estas observaciones surgen de mirar las gráficas, sin ningún test estadístico de por medio.

2.3. C. Limpieza de texto: `clean_text`

Se completó la función `clean_text(...)` provista en el notebook con varias transformaciones adicionales. La versión final aplica los siguientes pasos en este orden:

```
def clean_text(df, column_name):
    # 1. Eliminar la primera linea (suele contener titulo/header repetido).
    result = df[column_name].str.replace(r"^[^\n]*\n", "", regex=True)
    # 2. Pasar todo a minusculas.
    result = result.str.lower()
    # 3. Eliminar URLs (http/https): no aportan informacion lexica.
    result = result.str.replace(r'https?:\/\/\S+', ' ', regex=True)
    # 4. Eliminar todos los signos de puntuacion / caracteres no alfanumericos.
    #   [\w\s] captura . ! ; ( ) [ ] { } " ' - _ / < > # @ % & * + = ^ ~ `
    #   Se reemplaza por espacio para evitar que dos palabras queden pegadas.
    result = result.str.replace(r'[\w\s]', ' ', regex=True)
    # 5. Eliminar numeros aislados (fechas, cifras, porcentajes).
```

```
result = result.str.replace(r'\b\d+\b', ' ', regex=True)
# 6. Normalizar saltos de línea y tabulaciones a espacios.
result = result.str.replace(r'[\n\r\t]', ' ', regex=True)
# 7. Colapsar múltiples espacios consecutivos en uno solo.
result = result.str.replace(r'\s+', ' ', regex=True)
# 8. Eliminar espacios al inicio y al final.
result = result.str.strip()
return result
```

Justificación de cada transformación agregada respecto a la versión base:

- **Minúsculas:** evita que secuencias como “*President*” y “*president*” se cuenten como palabras distintas. Es la transformación mínima estándar para conteo de palabras.
- **Eliminar URLs:** en notas de prensa aparecen enlaces que no aportan información léxica para clasificar el medio (y pueden inflar el vocabulario con tokens raros).
- **Reemplazo por espacio en lugar de borrado al eliminar puntuación:** si se borra el guion o la barra sin reemplazarlo por espacio, dos palabras separadas por “-” o “/” quedarían pegadas como una sola.
- **Eliminar números aislados:** fechas, cifras y porcentajes no ayudan a discriminar el estilo editorial de cada medio (son ruido semántico para esta tarea).
- **Patrón regex generalizado:** el código de base tenía un bucle que cubría solo cinco símbolos. Se reemplazó por un único patrón que captura todos los caracteres que no son alfanuméricos ni espacios. Eso elimina en un solo paso toda la puntuación usual (puntos, comas, signos de pregunta y exclamación, paréntesis, corchetes, llaves, comillas, guiones, barras, etc.) sin tener que enumerarlas a mano.
- **Colapsar espacios múltiples y strip():** los pasos anteriores generan muchos espacios consecutivos; este paso final normaliza el resultado.

Verificación: se comparó el texto original contra el texto limpio en una muestra de artículos. Las cadenas resultantes consisten exclusivamente en secuencias de palabras alfanuméricas en minúscula separadas por un único espacio.

2.4. D. Elección del campo de texto a utilizar

Se eligió trabajar con el **cuerpo del artículo** (`article`).

El objetivo a futuro es construir un perfil de palabras que permita distinguir un medio de otro. Para eso, el volumen de texto importa: los títulos tienen en promedio del orden de 10 palabras (entre 9.0 y 11.8 palabras por título según el medio), lo que genera perfiles de frecuencia muy ruidosos y dependientes del tema puntual de cada nota. El cuerpo del artículo, en cambio, tiene varios cientos de palabras por artículo en todos los medios, lo que da mucha más señal para caracterizar el estilo editorial real.

La Tabla 3 resume el largo promedio de título y cuerpo por medio.

Cuadro 3: Largo promedio del título y del cuerpo del artículo (en palabras) por medio.

Medio	Título (media)	Cuerpo (media)	Cuerpo (mediana)
Reuters	9.9	281.7	209.0
The New York Times	9.0	905.8	848.5
CNBC	10.6	461.0	405.0
The Hill	11.8	572.0	464.0
People	9.7	419.0	371.0

Además, el cuerpo captura cosas que el título no: vocabulario técnico, estructura de los párrafos, referencias cruzadas, plantillas editoriales, etc. **Combinar ambos campos** (título + cuerpo) no aporta demasiado, porque el artículo en general ya contiene toda la información del título (y porque el peso relativo del título es despreciable frente al del cuerpo).

2.5. E. Pistas que identifican al medio de prensa

Una preocupación importante para una futura tarea de clasificación por medio es la presencia de **marcas en el texto que delaten al medio de manera directa**, sin requerir analizar el estilo editorial. Si esas marcas existen, una clasificadora puede aprender a detectarlas en lugar de aprender el estilo editorial.

Revisando manualmente una muestra aleatoria de artículos por medio y luego cuantificando con expresiones regulares sobre todo el corpus, se identificaron las siguientes pistas:

Reuters

- **Dateline al inicio del cuerpo:** el 91.9 % de los artículos contiene la marca **CIUDAD (Reuters)** - en el cuerpo.
- **Firma de cierre:** el 56.1 % termina con **Reporting by X; Editing by Y**.
- **Plantilla de *Further company coverage*:** aparece al final en el 24.2 % de los artículos.

Entre las tres marcas se cubre la enorme mayoría de los artículos del medio.

The Hill

- **Sufijo en el título:** el 100 % de los títulos termina con “| **TheHill**”.
- **Footer legal:** el 99.4 % de los artículos termina con el mismo footer (**Capitol Hill Publishing Corp.** con dirección, teléfonos y copyright).
- **URL **thehill.com** en cuerpo:** marginal pero presente.
- **Artefacto de scraping:** en algunos artículos los nombres de políticos quedan duplicados (*John McCainJohn Sidney McCain*), por una superposición del tag de link con el texto.

CNBC

- **Cables de Reuters republicados:** el 24.3 % de los artículos de *CNBC* tiene el dateline (**Reuters**) y/o la firma **Reporting by**, porque *CNBC* republica cables de la agencia.

- **Auto-mención:** el 34.8 % menciona “CNBC” en el cuerpo.
- **Footer Mad Money:** bloque recurrente que termina con `madcap@cnbc.com`.

A diferencia de *Reuters* o *The Hill*, no hay un único boilerplate que aparezca en la mayoría del contenido propio del medio.

The New York Times

- **Auto-mención:** el 18.9 % menciona “New York Times”.
- **URL `nytimes.com`:** presente en una fracción menor.
- **Footers por sección:** a diferencia de los otros medios, las pistas no son un único boilerplate sino *footers específicos por sección*: artículos de *Opinion* terminan con `@NYTopinion`, los de *Learning Network* con “*Learning Network staff*”, y los de *NY Today* con “*New York Today*”. Cada uno representa un porcentaje pequeño, pero todos son señales directas del medio.

People

- **Convención editorial `tells/told PEOPLE`:** el 28.4 % usa esta fórmula para atribuir citas, que es propia de la revista.
- **Auto-mención en mayúsculas:** el 50.3 % menciona “PEOPLE” en mayúsculas.
- **Footer *PEOPLE Now*:** bloque recurrente que promociona el programa de streaming del medio.
- **URL `people.com`:** muy escaso.

Verificación cruzada

Para confirmar que cada patrón es propio de su medio (y no aparece accidentalmente en otros), se hizo una verificación cruzada. La Tabla 4 muestra el porcentaje de artículos de cada medio que contiene cada uno de los patrones identificadores.

Cuadro 4: Porcentaje de artículos de cada medio que contiene cada patrón identificador. Los porcentajes altos en la columna del medio de origen y bajos en el resto confirman que el patrón identifica al medio.

Patrón	Reuters	The New York Times	CNBC	The Hill	People
Reuters dateline (Reuters)	91.9 %	0.2 %	24.3 %	0.1 %	0.0 %
The Hill TheHill en título	0.0 %	0.0 %	0.0 %	100.0 %	0.0 %
The Hill footer Capitol Hill	0.0 %	0.0 %	0.0 %	99.4 %	0.0 %
CNBC mencionado en cuerpo	0.3 %	0.5 %	34.8 %	0.6 %	0.2 %
NYT <code>nytimes.com</code> en cuerpo	0.0 %	8.4 %	0.0 %	0.0 %	0.0 %
People <code>tells/told PEOPLE</code>	0.0 %	0.0 %	0.0 %	0.0 %	28.4 %

Cada patrón aparece sobre todo en su medio de origen y casi no en los demás. La única excepción es el dateline (Reuters), que también aparece en *CNBC* porque *CNBC* republica cables de la agencia.

Además, la columna `url`

El dominio de la `url` identifica al medio al 100 % en todos los casos. Sin embargo, en este trabajo el objetivo es clasificar a partir del *texto* de los artículos, por lo que la columna `url` no debe usarse como predictor; se la considera útil únicamente como ground-truth (junto con `publication`).

Decisión: eliminar o reducir el impacto de las pistas

Para una tarea de clasificación por estilo editorial, **conviene reducir el impacto de estas marcas**. Las dos opciones consideradas son:

1. **Eliminarlas como plantillas** (regex sobre el texto crudo) antes del conteo de palabras. Es lo que se aplica en la Parte 2: regex específicas para el dateline de *Reuters*, el footer legal de *The Hill*, el handle @NYTopinion de *NYT*, etc.
2. **Eliminar tokens aislados** (*reuters*, *cnbc*, *nytimes*, *thehill*, *nyt*, *people*) cuando aparezcan como palabras sueltas tras la tokenización.

Las dos opciones se complementan: la primera limpia frases completas (evitando que palabras genuinas como *capitol* o *hill* se pierdan por estar dentro de una plantilla), mientras que la segunda atrapa menciones aisladas que se escapan a las regex.

2.6. F. Restricción por sección temática o período temporal

Restricción por sección temática

La idea es interesante en principio: si se comparan artículos del mismo tema, cualquier diferencia en frecuencia de palabras refleja estilo editorial y no simplemente el *topic*. Sin embargo, en este dataset hay dos problemas concretos que la hacen inviable:

- ***The Hill* no tiene la columna `section`** reportada en ninguno de sus artículos (2349 de 2349 artículos, 100 % sin sección).
- ***People* cubre exclusivamente entretenimiento** (*tv*, *movies*, *celebrity*, *style*) y no tiene artículos de política ni economía, que son los temas dominantes en los otros cuatro medios. Restringir por una sección común equivaldría a eliminar *People* del análisis.

Además, **el tema que cubre cada medio es parte de su identidad editorial**: *Reuters* es una agencia de cables financieros y *People* una revista de celebrities. Esa diferencia temática es información útil para clasificar, no algo que convenga descartar.

La Tabla 5 resume las secciones más frecuentes en cada medio.

Cuadro 5: Secciones más frecuentes por medio (top 5) y proporción de artículos sin sección reportada.

Medio	% sin sección	Top 5 secciones
Reuters	1 %	<i>World News</i> (1.227), <i>Market News</i> (1.218), <i>Business News</i> (1.076), <i>Financials</i> (679), <i>Intel</i> (465)
The New York Times	2 %	<i>world</i> (329), <i>opinion</i> (319), <i>us</i> (297), <i>arts</i> (239), <i>sports</i> (235)
CNBC	18 %	<i>Wires</i> (733), <i>Politics</i> (175), <i>Tech</i> (146), <i>Markets</i> (64), <i>Market Insider</i> (63)
The Hill	100 %	sin datos de sección
People	0 %	<i>tv</i> (280), <i>movies</i> (153), <i>style</i> (136), <i>crime</i> (130), <i>celebrity</i> (112)

Restricción por período temporal

Los cinco medios cubren aproximadamente el mismo período (de 2016-01-01 a 2020-04-01), con distribución bastante uniforme. No hay un argumento fuerte para acotarlo: restringir a un año en particular reduciría el tamaño de muestra de forma significativa sin eliminar el problema del sesgo temático, que es la razón principal por la que se evaluaría esta restricción.

Decisión

No se aplica ninguna de las dos restricciones en este trabajo, por las razones expuestas: la restricción por sección elimina información legítima del estilo editorial, y la restricción temporal no aporta una ganancia evidente.

3. Parte 2: Conteo de palabras y visualizaciones

Preparación: tokens limpios

Para los conteos de palabras de esta parte se construye una columna **Tokens** que parte de **CleanText** (Parte 1.C) y le aplica dos filtros adicionales:

- **Stopwords en inglés** (lista de NLTK): *the, of, to, and, in, ...*. Son las palabras más frecuentes del idioma y no diferencian un medio de otro, por lo que dominarían cualquier ranking sin aportar información.
- **Identificadores del propio medio** detectados en 1.E (*reuters, cnbc, nytimes, nyt, thehill, ...*). Si no se eliminaran, el ranking de palabras frecuentes de cada medio quedaría encabezado por el nombre del propio medio, lo cual es un resultado trivial y oculta las diferencias reales.

Además, antes de tokenizar se remueven mediante regex las plantillas reiteradas (dateline de Reuters, firmas “*Reporting by*” / “*Editing by*”, footer legal de *The Hill*, etc.). Si solo se filtraran las palabras sueltas, palabras legítimas como *capitol* o *hill* se perderían por estar dentro del footer; eliminando la frase completa solo se descarta el boilerplate y se preservan esas palabras cuando aparecen en contextos editoriales reales.

3.1. A. Palabras más frecuentes por medio

Se construye un ranking de las palabras más frecuentes para cada uno de los cinco medios. La frecuencia se reporta en términos **relativos** (porcentaje sobre el total de tokens del medio), porque los volúmenes de texto son muy distintos entre medios y los conteos absolutos no son comparables.


Se incluyó primero una versión **ingenua** (sobre **CleanText**, sin filtrar stopwords ni pistas) para evidenciar el problema: los rankings de los cinco medios resultan casi idénticos, encabezados siempre por las mismas palabras funcionales del inglés (*the, of, to, and, ...*). El gráfico es poco informativo y no permite comparar nada entre medios.

La versión **filtrada** (sobre **Tokens**, ya sin stopwords ni identificadores del medio) muestra diferencias claras entre medios: vocabulario financiero y de cable en Reuters y CNBC, vocabulario político en The Hill, más narrativo en NYT, y de entretenimiento y celebrities en People. También se armó un *heatmap* con las top-10 palabras de cada medio en la misma escala, donde se ve por ejemplo que *trump* o *house* pesan muy distinto en The Hill que en People.


Ideas para modificar la visualización (sin implementar).

- **Por sección temática:** rehacer el top-N restringiéndose a una misma **section** (por ejemplo *politics*); lo que aparece son diferencias de estilo dentro del mismo tema y no diferencias de cobertura. Limitación: *The Hill* no reporta sección y *People* cubre casi solo entretenimiento.
- **Por fecha:** graficar la serie de tiempo (por mes o trimestre) de unas pocas palabras-clave (*trump, biden, covid, election, ...*) por medio, para ver cómo reacciona cada medio frente a un mismo evento; o comparar el top-N de un año contra el de otro dentro del mismo medio para detectar cambios de agenda.

Versión ingenua — top 20 palabras por medio sobre CleanText (sin filtrar stopwords ni pistas del medio)



Versión filtrada — top 20 palabras por medio sobre Tokens (sin stopwords ni pistas del medio)



Heatmap – frecuencia relativa (%) de las top 10 palabras de cada medio (versión filtrada)




Figura 3: Top 20 palabras por medio. Arriba: versión ingenua sobre **CleanText** (dominada por *stopwords*, rankings casi idénticos entre medios). Centro: versión filtrada sobre **Tokens** (sin *stopwords* ni identificadores del medio). Abajo: *heatmap* con la frecuencia relativa (%) de las top-10 palabras de cada medio en la misma escala.

- **Por tipo de noticia:** usar `section` como proxy de tipo (*opinion* / *business* / *politics* / *sports* / ...) y rehacer la visualización agrupando por tipo en lugar de por medio.

3.2. B. Medios con mayor cantidad de palabras

Se cuenta el total de palabras (separadas por espacios sobre `CleanText`) por medio. La Figura 4 muestra tres vistas complementarias: total, promedio por artículo, y promedio de palabras distintas por artículo.




Figura 4: Cantidad de palabras por medio. Izquierda: total acumulado. Centro: promedio por artículo. Derecha: promedio de palabras distintas (vocabulario) por artículo.

Problema observado. El gráfico de la izquierda está dominado por *Reuters* y *NYT* con cifras parecidas (alrededor de 2,6 millones de palabras cada uno), seguidos a distancia por el resto. Esa lectura es engañosa: *Reuters* aporta tantas palabras porque tiene **muchos más artículos** que el resto (9.431 frente a 1.500–2.800 de los otros, ver Tabla 2), no porque sus artículos sean largos. El total de palabras mezcla dos cosas distintas en una sola cifra: cantidad de artículos y largo medio por artículo.

Forma de resolverlo. La métrica adecuada para comparar el largo de las notas es el **promedio de palabras por artículo** (gráfico del centro). Con ese cambio el orden se invierte: *NYT* pasa a ser el medio con notas más largas (917 palabras por artículo en promedio), seguido por *The Hill* (574), *CNBC* (463) y *People* (426), y *Reuters* queda último (279), lo que encaja con su perfil de cable corto. El cambio de orden entre las dos vistas deja claro que el total y el promedio responden preguntas distintas.

Riqueza léxica. El tercer gráfico (palabras distintas por artículo en promedio) no lo pide la consigna pero aporta una idea simple de **riqueza léxica**: dos medios pueden escribir notas del mismo largo y aun así usar vocabulario muy distinto. El orden coincide con el del largo medio *NYT* encabeza con 403 palabras distintas por artículo, seguido por *The Hill* (293), *CNBC* (229), *People* (218) y *Reuters* (151) pero la brecha relativa es aún más marcada: *NYT* usa casi 2,7 veces más vocabulario distinto por nota que *Reuters*. Tiene sentido: *Reuters* repite estructuras de cable, mientras que *NYT* escribe notas largas y de temas variados.

3.3. C. Matriz de menciones entre medios

Se construye una matriz 5×5 donde la entrada (i, j) cuenta cuántas veces los artículos del medio i mencionan al medio j . El conteo se hace sobre el texto original (sin `clean_text`) para preservar mayúsculas y poder distinguir, por ejemplo, el nombre propio “*People*” (revista) de la palabra común “*people*”.

Para cada medio se definió un patrón regex con los nombres con los que aparece mencionado en los textos:

- *Reuters*: **Reuters** (case-insensitive).
- *The Hill*: **The Hill** o **TheHill**.
- *CNBC*: **CNBC**.
- *The New York Times*: **The New York Times**, **NYT** o **nytimes**.
- *People*: las formas estrictas (**PEOPLE** en mayúsculas, **People** magazine, **people.com**) y además **People** cuando aparece en mitad de oración. Esto último se logra con un lookbehind que exige que el carácter anterior sea letra minúscula, coma, punto y coma o dos puntos más espacio. Así se descarta “*People*” como inicio de oración (donde podría ser la palabra común) y se conserva cuando aparece en frases como “*told People that...*” o “*..., People reported...*”, que es muy probable que refieran a la revista.

Además del conteo absoluto, se calcula una **matriz normalizada**: el porcentaje de artículos del medio i que mencionan al menos una vez al medio j . Esta segunda vista no depende del volumen total de notas (recordar que *Reuters* tiene casi $4\times$ más notas que *People*) y permite comparar de forma más justa qué tan presente está cada medio en la cobertura de los demás.




Figura 5: Menciones entre medios. Izquierda: conteo total. Derecha: porcentaje de artículos del medio i que contienen al menos una mención al medio j . Diagonal enmascarada en ambos.

La diagonal (auto-menciones) se enmascara porque las auto-referencias son muy altas (*Reuters* se menciona a sí mismo 11.623 veces, presente en 94 % de sus artículos) y aportan poco al objetivo de la matriz.

Observaciones.

- **CNBC depende fuertemente de Reuters como fuente.** En conteo absoluto son 1.199 menciones, muy por encima de cualquier otro par. La vista normalizada lo precisa todavía más: **el 31,8% de los artículos de CNBC mencionan a Reuters**, una tasa enorme comparada con cualquier otro par. Esto es consistente con lo observado en 1.E, donde un 24% de los artículos de CNBC incluían el dateline “(Reuters)”: CNBC republica o referencia cables de Reuters con frecuencia.
- **Las menciones no son simétricas.** *The Hill* menciona a *NYT* en 6,5% de sus artículos, pero *NYT* menciona a *The Hill* en solo 0,2%. *The Hill* usa al *NYT* como fuente o referencia mucho más de lo que el *NYT* habla de *The Hill*. Algo similar pasa con *The Hill* citando a *Reuters* (3,0% de sus artículos) frente a *Reuters* citando a *The Hill* (0%).
- **Reuters apenas menciona al resto.** En cifras normalizadas, menciona a cualquier otro medio en menos del 1% de sus artículos (0,3% a *NYT*, 0,3% a *CNBC*, 0,9% a *People*, 0% a *The Hill*). Como agencia de cables, su trabajo es informar hechos más que comentar lo que dicen otros medios.
- **NYT y People escriben de forma más autónoma.** Mirando la fila de cada uno, en el resto de la matriz casi todas las entradas están por debajo del 3%. *NYT* y *People* apenas usan a los demás medios como fuente, contrario a *CNBC* y *The Hill*.
- **Normalizar cambia qué par aparece como dominante.** En el conteo absoluto, *The Hill* citando a *NYT* (180 menciones) llamaba la atención, pero al normalizar baja a 6,5% de los artículos de *The Hill*, una fracción chica frente al 31,8% de *CNBC* mencionando a *Reuters*. La matriz normalizada corrige el sesgo por volumen total de artículos.

3.4. D. Preguntas propuestas

A partir de los datos analizados se proponen tres preguntas que podrían explorarse en trabajos posteriores, junto con un camino de análisis sin implementar.

Pregunta 1 – Largo de los artículos. *¿Cómo se distribuye el largo de los artículos dentro de cada medio? ¿Hay medios con largos muy homogéneos y otros con mucha varianza?*

Camino. Aprovechando la columna `NumWords` calculada en 2.B, mirar las distribuciones por medio (mediana, desvío estándar y un boxplot por medio). El promedio mostrado en 2.B esconde la dispersión: un medio puede tener un promedio similar a otro y aun así alternar entre cables muy cortos y notas muy largas. El boxplot permite distinguir medios con largos parejos de medios que mezclan formatos.

Pregunta 2 – Reciprocidad de las menciones. *¿Las menciones entre medios son recíprocas? ¿Cuáles pares son simétricos y cuáles muy asimétricos?*

Camino. Comparar la matriz `mentions_matrix` de 2.C con su traspuesta. Si la entrada (i, j) es muy distinta de (j, i) , hay una asimetría: el medio i depende de j como fuente pero no al revés. Las observaciones de 2.C ya muestran indicios fuertes (*The Hill* cita a *NYT* 180 veces, *NYT* a

The Hill solo 7); una inspección par a par permitiría caracterizar mejor qué medios usan a qué otros medios como fuente.

Pregunta 3 – Vocabulario distintivo por medio. *Más allá de los identificadores obvios (nombres del propio medio, firmas), ¿cada medio tiene un vocabulario propio que lo diferencia del resto?*

Camino. Partiendo de los **Tokens** ya filtrados en 2.A, calcular para cada palabra su frecuencia relativa en cada medio y quedarse con las palabras que aparecen mucho en un medio y poco en los otros (alta diferencia entre el máximo y el mínimo de su frecuencia entre los cinco medios). El heatmap de 2.A ya hace una versión inicial de esto sobre el top-N de cada medio; el camino aquí es extenderlo a todo el vocabulario para detectar palabras distintivas que no necesariamente están en el top, pero sí son características de un único medio.