



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Tarea 1

Introducción a la Ciencia de Datos

Edición 2026

Integrantes:

Tomás Alejo Spoturno Gonzalez, 5.165.789-6

Nicolás Buero

Universidad de la República
Facultad de Ingeniería

Mayo 2026

Índice

1. Introducción	2
2. Parte 1: Cargado y Limpieza de Datos	2
2.1. A. Exploración de datos y selección de los 5 medios principales	2
2.2. B. Visualización temporal	3
2.3. C. Limpieza de texto: <code>clean_text</code>	5
2.4. D. Elección del campo de texto a utilizar	6
2.5. E. Pistas que identifican al medio de prensa	7
2.6. F. Restricción por sección temática o período temporal	9

1. Introducción

Este informe documenta la resolución de la Tarea 1 del curso *Introducción a la Ciencia de Datos* (edición 2026). El trabajo se realiza sobre un subconjunto muestreado del dataset abierto *All the News 2.1 – Component One*, que contiene artículos de noticias publicados en distintos medios de prensa. El objetivo de esta primera entrega es **cargar, explorar y limpiar** los datos, con vistas a una futura tarea de clasificación automática de textos por medio de prensa.

El código se encuentra en el notebook `Tarea_1/2026_template_tarea1.ipynb` del repositorio. En este informe se reportan los resultados y las decisiones tomadas; las visualizaciones y tablas se reproducen a partir del notebook ejecutado.

2. Parte 1: Cargado y Limpieza de Datos

2.1. A. Exploración de datos y selección de los 5 medios principales

Composición del DataFrame

El DataFrame cargado contiene 30.213 artículos y 12 columnas. Las columnas son: `idx`, `article_idx`, `date`, `year`, `month`, `day`, `author`, `title`, `article`, `url`, `section`, `publication`. Cada fila representa un artículo de noticias, con metadatos (`publication`, `author`, `date`, `section`, `url`) y el contenido textual (`title`, `article`).

Datos faltantes por columna

Se evaluó la cantidad de valores nulos en cada columna. La Tabla 1 resume las columnas con datos faltantes.

Cuadro 1: Columnas con datos faltantes en el DataFrame.

Columna	Faltantes	%
<code>author</code>	11.405	37.75 %
<code>section</code>	10.232	33.87 %
<code>article</code>	1.176	3.89 %
<code>url</code>	141	0.47 %
<code>publication</code>	141	0.47 %

Las columnas con datos faltantes más significativos son `section` y `author`: ambas tienen una proporción alta de valores nulos. `section` no está disponible para todos los medios (por ejemplo, *The Hill* no la reporta), y `author` puede faltar en cables de agencia o en notas sin firma. El resto de los campos críticos (`publication`, `date`, `title`, `article`) están prácticamente completos.

Otros problemas de calidad

Además de los faltantes, se identificaron los siguientes problemas mediante chequeos manuales:

- **Redundancia entre `idx` y `article_idx`:** ambas columnas son idénticas en 0 filas (es decir, son idénticas en todas las filas). Una de las dos es redundante.
- **Formato heterogéneo en `date`:** conviven los formatos `YYYY-MM-DD` y `YYYY-MM-DD HH:MM:SS` en distintas filas. Esto obliga a usar `format='mixed'` al parsear.
- **Tipo de `month`:** la columna `month` se almacena como cadena de texto (`str`), no como entero, a pesar de contener únicamente valores numéricos del 1 al 12. Lo mismo ocurre con `year` y `day`. Conviene convertirlas a entero si se las quisiera utilizar para operaciones numéricas, aunque como se discute más abajo son redundantes con `date`.
- **Redundancia entre `date` y `year`, `month`, `day`:** las tres últimas son derivables exactamente de `date`. Se verificó consistencia (año, mes y día coinciden con el `date` parseado en todos los registros donde ambos existen). Por lo tanto pueden eliminarse sin pérdida de información.
- **URLs:** de las 30.072 URLs presentes, las 30.072 son válidas según un chequeo regex (esquema `http/https` y caracteres válidos). No se encontraron URLs con formato inválido en el corpus.

Selección de los 5 medios principales

El dataset contiene artículos de 26 medios de prensa, con una distribución muy desbalanceada. Para el resto del análisis se trabaja con los **cinco medios con mayor cantidad de artículos**, cuyos conteos se muestran en la Tabla 2.

Cuadro 2: Top 5 medios con mayor cantidad de artículos en el dataset.

Medio	Artículos	% del total
Reuters	9.431	31.2 %
The New York Times	2.840	9.4 %
CNBC	2.623	8.7 %
The Hill	2.349	7.8 %
People	1.528	5.1 %
Total top 5	18.771	62.1 %

A partir de este punto, todos los análisis se realizan sobre el sub-DataFrame `df_top_5`, que contiene 18.771 artículos.

2.2. B. Visualización temporal

Para visualizar la actividad de los cinco medios a lo largo del tiempo, se generó primero una serie por mes y otra por año (ver Figura 1).




Figura 1: Cantidad de artículos publicados por los 5 medios a lo largo del tiempo (granularidad mes y año).

Observaciones generales. Los cinco medios cubren aproximadamente el mismo período (de 2016-01-01 a 2020-04-01). La cobertura es relativamente uniforme a lo largo de los años, sin saltos abruptos que sugieran cortes en la ingesta del dataset. *Reuters* y *The Hill* son los que aportan más artículos por mes, mientras que *People* mantiene un volumen más bajo y estable.

Para detectar patrones cíclicos más finos, se calculó el promedio de artículos por día de la semana y por mes del año (Figura 2).




Figura 2: Promedio de artículos por día de la semana y por mes del año.

Patrones cíclicos.

- En los **días de la semana** se observa una caída clara los sábados y domingos en los medios de tipo agencia y política (*Reuters*, *The Hill*, *CNBC*, *NYT*). *People*, en cambio, mantiene un volumen más parejo, consistente con un perfil editorial de entretenimiento que no depende de la agenda institucional de la semana laboral.
- Por **mes del año** no hay un patrón estacional tan marcado: los medios cubren noticias de forma continua durante todo el año.

No se realizó ningún test estadístico; los comentarios se basan exclusivamente en la inspección visual de las gráficas.

2.3. C. Limpieza de texto: `clean_text`

Se completó la función `clean_text(...)` provista en el notebook con varias transformaciones adicionales. La versión final aplica los siguientes pasos en este orden:

```
def clean_text(df, column_name):
    # 1. Eliminar la primera línea (suele contener título/header repetido).
    result = df[column_name].str.replace(r"^[^\n]*\n", "", regex=True)
    # 2. Pasar todo a minúsculas.
    result = result.str.lower()
    # 3. Eliminar URLs (http/https): no aportan información léxica.
    result = result.str.replace(r'https?://\S+', ' ', regex=True)
    # 4. Eliminar todos los signos de puntuación / caracteres no alfanuméricos.
    #    [\w\s] captura . ! ; ( ) [ ] { } " ' - _ / | < > # @ % & * + = ^ ~ '
    #    Se reemplaza por espacio para evitar que dos palabras queden pegadas.
    result = result.str.replace(r'[^\w\s]', ' ', regex=True)
```

```
# 5. Eliminar numeros aislados (fechas, cifras, porcentajes).
result = result.str.replace(r'\b\d+\b', ' ', regex=True)
# 6. Normalizar saltos de línea y tabulaciones a espacios.
result = result.str.replace(r'[\n\r\t]', ' ', regex=True)
# 7. Colapsar multiples espacios consecutivos en uno solo.
result = result.str.replace(r'\s+', ' ', regex=True)
# 8. Eliminar espacios al inicio y al final.
result = result.str.strip()
return result
```

Justificación de cada transformación agregada respecto a la versión base:

- **Minúsculas:** evita que secuencias como “*President*” y “*president*” se cuenten como palabras distintas. Es la transformación mínima estándar para conteo de palabras.
- **Eliminar URLs:** en notas de prensa aparecen enlaces que no aportan información léxica para clasificar el medio (y pueden inflar el vocabulario con tokens raros).
- **Reemplazo por espacio en lugar de borrado al eliminar puntuación:** si se borra el guion o la barra sin reemplazarlo por espacio, dos palabras separadas por “-” o “/” quedarían pegadas como una sola.
- **Eliminar números aislados:** fechas, cifras y porcentajes no ayudan a discriminar el estilo editorial de cada medio (son ruido semántico para esta tarea).
- **Patrón regex generalizado:** el código de base tenía un bucle que cubría solo cinco símbolos. Se reemplazó por un único patrón que captura todos los caracteres que no son alfanuméricos ni espacios. Eso elimina en un solo paso toda la puntuación usual (puntos, comas, signos de pregunta y exclamación, paréntesis, corchetes, llaves, comillas, guiones, barras, etc.) sin tener que enumerarlas a mano.
- **Colapsar espacios múltiples y strip():** los pasos anteriores generan muchos espacios consecutivos; este paso final normaliza el resultado.

Verificación: se comparó el texto original contra el texto limpio en una muestra de artículos. Las cadenas resultantes consisten exclusivamente en secuencias de palabras alfanuméricas en minúscula separadas por un único espacio.

2.4. D. Elección del campo de texto a utilizar

Se eligió trabajar con el **cuerpo del artículo** (`article`).

El objetivo a futuro es construir un perfil de palabras que permita distinguir un medio de otro. Para eso, el volumen de texto importa: los títulos tienen en promedio del orden de 10 palabras (entre 9.0 y 11.8 palabras por título según el medio), lo que genera perfiles de frecuencia muy ruidosos y dependientes del tema puntual de cada nota. El cuerpo del artículo, en cambio, tiene varios cientos de palabras por artículo en todos los medios, lo que da mucha más señal para caracterizar el estilo editorial real.

La Tabla 3 resume el largo promedio de título y cuerpo por medio.

Cuadro 3: Largo promedio del título y del cuerpo del artículo (en palabras) por medio.

Medio	Título (media)	Cuerpo (media)	Cuerpo (mediana)
Reuters	9.9	281.7	209.0
The New York Times	9.0	905.8	848.5
CNBC	10.6	461.0	405.0
The Hill	11.8	572.0	464.0
People	9.7	419.0	371.0

Además, el cuerpo captura cosas que el título no: vocabulario técnico, estructura de los párrafos, referencias cruzadas, plantillas editoriales, etc. **Combinar ambos campos** (título + cuerpo) no aporta demasiado, porque el artículo en general ya contiene toda la información del título (y porque el peso relativo del título es despreciable frente al del cuerpo).

2.5. E. Pistas que identifican al medio de prensa

Una preocupación importante para una futura tarea de clasificación por medio es la presencia de **marcas en el texto que delaten al medio de manera directa**, sin requerir analizar el estilo editorial. Si esas marcas existen, una clasificadora puede “hacer trampa” aprendiendo a detectar la marca en lugar de aprender el estilo.

Revisando manualmente una muestra aleatoria de artículos por medio y luego cuantificando con expresiones regulares sobre todo el corpus, se identificaron las siguientes pistas:

Reuters

- **Dateline al inicio del cuerpo:** el 91.9 % de los artículos contiene la marca **CIUDAD (Reuters)** – en el cuerpo. Es la firma más reconocible de la agencia.
- **Firma de cierre:** el 56.1 % termina con **Reporting by X; Editing by Y**.
- **Plantilla de *Further company coverage*:** aparece al final en el 24.2 % de los artículos.

Son tres marcas acumuladas que identifican a *Reuters* de forma casi inequívoca.

The Hill

- **Sufijo en el título:** el 100.0 % de los títulos termina con “| **TheHill**”. Es una marca 100 %-sistemática.
- **Footer legal:** el 99.4 % de los artículos termina con el mismo footer (**Capitol Hill Publishing Corp.** con dirección, teléfonos y copyright).
- **URL **thehill.com** en cuerpo:** marginal pero presente.
- **Artefacto de scraping:** en algunos artículos los nombres de políticos quedan duplicados (*John McCainJohn Sidney McCain*), por una superposición del tag de link con el texto.

CNBC

- **Cables de Reuters republicados:** el 24.3 % de los artículos de *CNBC* tiene el dateline (Reuters) y/o la firma **Reporting by**, porque *CNBC* republica cables de la agencia.
- **Auto-mención:** el 34.8 % menciona “CNBC” en el cuerpo.
- **Footer Mad Money:** bloque recurrente que termina con `madcap@cnbc.com`.

No hay un boilerplate tan uniforme como en *Reuters* o *The Hill* para el contenido original.

The New York Times

- **Auto-mención:** el 18.9 % menciona “New York Times”.
- **URL `nytimes.com`:** presente en una fracción menor.
- **Footers por sección:** a diferencia de los otros medios, las pistas no son un único boilerplate sino *footers específicos por sección*: artículos de *Opinion* terminan con `@NYTopinion`, los de *Learning Network* con “*Learning Network staff*”, y los de *NY Today* con “*New York Today*”. Cada uno representa un porcentaje pequeño, pero todos son señales directas del medio.

People

- **Convención editorial `tells/told PEOPLE`:** el 28.4 % usa esta fórmula para atribuir citas, que es propia de la revista.
- **Auto-mención en mayúsculas:** el 50.3 % menciona “PEOPLE” en mayúsculas.
- **Footer *PEOPLE Now*:** bloque recurrente que promociona el programa de streaming del medio.
- **URL `people.com`:** muy escaso.

Verificación cruzada

Para confirmar que cada patrón es propio de su medio (y no aparece accidentalmente en otros), se hizo una verificación cruzada. La Tabla 4 muestra el porcentaje de artículos de cada medio que contiene cada uno de los patrones identificadores.

Cuadro 4: Porcentaje de artículos de cada medio que contiene cada patrón identificador. Los porcentajes altos en la columna del medio de origen y bajos en el resto confirman que el patrón identifica al medio.

Patrón	Reuters	The New York Times	CNBC	The Hill	People
Reuters dateline (Reuters)	91.9 %	0.2 %	24.3 %	0.1 %	0.0 %
The Hill TheHill en título	0.0 %	0.0 %	0.0 %	100.0 %	0.0 %
The Hill footer Capitol Hill	0.0 %	0.0 %	0.0 %	99.4 %	0.0 %
CNBC mencionado en cuerpo	0.3 %	0.5 %	34.8 %	0.6 %	0.2 %
NYT <code>nytimes.com</code> en cuerpo	0.0 %	8.4 %	0.0 %	0.0 %	0.0 %
People <code>tells/told PEOPLE</code>	0.0 %	0.0 %	0.0 %	0.0 %	28.4 %

Como era esperable, los patrones tienen alta concentración en su medio de origen y baja presencia en los demás; la única excepción notable es el dateline (**Reuters**) que también aparece en *CNBC* por la republicación de cables.

Además, la columna `url`

El dominio de la `url` identifica al medio al 100% en todos los casos. Sin embargo, en este trabajo el objetivo es clasificar a partir del *texto* de los artículos, por lo que la columna `url` no debe usarse como predictor; se la considera útil únicamente como ground-truth (junto con `publication`).

Decisión: eliminar o reducir el impacto de las pistas

Para una tarea de clasificación por estilo editorial, **conviene reducir el impacto de estas marcas**. Las dos opciones consideradas son:

1. **Eliminarlas como plantillas** (regex sobre el texto crudo) antes del conteo de palabras. Esta es la decisión adoptada para la Parte 2 (no documentada en este informe): se definen patrones específicos para el dateline de *Reuters*, el footer legal de *The Hill*, el handle @NYTopinion de *NYT*, etc.
2. **Eliminar tokens aislados** (`reuters`, `cnbc`, `nytimes`, `thehill`, `nyt`, `people`) cuando aparecen como palabras sueltas tras la tokenización.

Las dos opciones se complementan: la primera limpia frases completas (evitando que palabras genuinas como `capitol` o `hill` se pierdan por estar dentro de una plantilla), mientras que la segunda atrapa menciones aisladas que se escapan a las regex.

2.6. F. Restricción por sección temática o período temporal

Restricción por sección temática

La idea es interesante en principio: si se comparan artículos del mismo tema, cualquier diferencia en frecuencia de palabras refleja estilo editorial y no simplemente el *topic*. Sin embargo, en este dataset hay dos problemas concretos que la hacen inviable:

- ***The Hill* no tiene la columna `section`** reportada en ninguno de sus artículos (2349 de 2349 artículos, 100% sin sección).
- ***People* cubre exclusivamente entretenimiento** (*tv*, *movies*, *celebrity*, *style*) y no tiene artículos de política ni economía, que son los temas dominantes en los otros cuatro medios. Restringir por una sección común equivaldría a eliminar *People* del análisis.

Además, conceptualmente, **el tema que cubre cada medio es parte de su identidad editorial**: *Reuters* es una agencia de cable financiera, *People* es una revista de celebrities. Esa diferencia temática no es “ruido”, sino una característica real del medio que una clasificadora puede (y debería) aprovechar.

La Tabla 5 resume las secciones más frecuentes en cada medio.

Cuadro 5: Secciones más frecuentes por medio (top 5) y proporción de artículos sin sección reportada.

Medio	% sin sección	Top 5 secciones
Reuters	1 %	<i>World News</i> (1.227), <i>Market News</i> (1.218), <i>Business News</i> (1.076), <i>Financials</i> (679), <i>Intel</i> (465)
The New York Times	2 %	<i>world</i> (329), <i>opinion</i> (319), <i>us</i> (297), <i>arts</i> (239), <i>sports</i> (235)
CNBC	18 %	<i>Wires</i> (733), <i>Politics</i> (175), <i>Tech</i> (146), <i>Markets</i> (64), <i>Market Insider</i> (63)
The Hill	100 %	sin datos de sección
People	0 %	<i>tv</i> (280), <i>movies</i> (153), <i>style</i> (136), <i>crime</i> (130), <i>celebrity</i> (112)

Restricción por período temporal

Los cinco medios cubren aproximadamente el mismo período (de 2016-01-01 a 2020-04-01), con distribución bastante uniforme. No hay un argumento fuerte para acotarlo: restringir a un año en particular reduciría el tamaño de muestra de forma significativa sin eliminar el problema del sesgo temático, que es la razón principal por la que se evaluaría esta restricción.

Decisión

No se aplica ninguna de las dos restricciones en este trabajo, por las razones expuestas: la restricción por sección elimina información legítima del estilo editorial, y la restricción temporal no aporta una ganancia evidente.