

Tarea 1 | Introducción a la Ciencia de Datos

Análisis exploratorio del corpus All the News 2.1

Tomás Alejo Spoturno Nicolás Buero

Facultad de Ingeniería, Universidad de la República

Mayo 2026, Grupo 23

Repo: <https://github.com/Nicolasvb23/intro-cd>

Dataset

- 30.213 artículos, 26 medios.
- Top 5 (62 %): Reuters, NYT, CNBC, The Hill, People.

Calidad

- author 38 %, section 34 %, article 4 % nulos.
- date: dos formatos → format=mixed.
- year/month/day redundantes con date.
- month como str con valores tipo "1.0".

clean_text


1. Minúsculas.
2. Eliminar URLs.
3. Puntuación → espacio (no borrado).
4. Eliminar números aislados.
5. Colapsar espacios.

Campo elegido: cuerpo del artículo.


Medio	Artículos	% del corpus
Reuters	9.431	31,2 %
The New York Times	2.840	9,4 %
CNBC	2.623	8,7 %
The Hill	2.349	7,8 %
People	1.528	5,1 %
Top 5	62 % del corpus total	
Otros 21 medios	11.442	37,9 %

Reuters concentra más de la mitad del top-5: su volumen refleja la producción de una **agencia de cable**, no de una redacción editorial clásica.


Artículos publicados a lo largo del tiempo



Artículos publicados por año



Patrones cíclicos de publicación




No se acotó por período: cobertura uniforme 2016-2020, sin argumento fuerte para restringir.

Pistas que identifican al medio

Patrón	Reuters	NYT	CNBC	The Hill	People
Reuters dateline (Reuters)	91,9 %	0,2 %	24,3 %	0,1 %	0,0 %
Título TheHill	0,0 %	0,0 %	0,0 %	100 %	0,0 %
Footer Capitol Hill	0,0 %	0,0 %	0,0 %	99,4 %	0,0 %
CNBC mencionado en cuerpo	0,3 %	0,5 %	34,8 %	0,6 %	0,2 %
nytimes.com en cuerpo	0,0 %	8,4 %	0,0 %	0,0 %	0,0 %
People tells/told PEOPLE	0,0 %	0,0 %	0,0 %	0,0 %	28,4 %

- Cada patrón es casi exclusivo de **su medio de origen**.
- Excepción: dateline y firma de Reuters en CNBC → CNBC republica cables.
- No se acotó por sección: People solo cubre entretenimiento; The Hill no tiene datos de sección.

Palabras frecuentes por medio






Perfiles editoriales claros:


- **Reuters:** financiero
percent, company, market
- **The Hill:** político
trump, house, senate
- **People:** celebrities
family, love, star
- **NYT & CNBC:** político-económico

Sin filtrar stopwords los rankings son **idénticos** entre medios.

Largo y riqueza léxica por medio



Matriz de menciones entre medios



Izq: conteo total; der: % de artículos del medio i que mencionan a j . Diagonal enmascarada.

- **CNBC** cita Reuters en el **31,8 %** de sus artículos → republica cables.
- **Asimetría**: The Hill → NYT (6,5 %) pero NYT → The Hill (0,2 %).
- **NYT y People** son autónomos: citan poco a otros (< 3 %).
- **Truco**: *lookbehind* para detectar *People* (revista) vs. *people* (palabra común): solo cuenta precedido de contexto (told People, , People reported).

Tres preguntas que abre el análisis:

1. **Reciprocidad de menciones:** ¿qué pares son simétricos y cuáles asimétricos?
2. **Vocabulario distintivo:** ¿qué palabras son propias de un medio, no solo frecuentes?
3. **Varianza en el largo:** ¿qué medios son homogéneos y cuáles tienen alta dispersión?

¡Gracias!