



FACULTAD DE
INGENIERÍA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Tarea 2

Introducción a la Ciencia de Datos

Edición 2026

Integrantes:

Tomás Alejo Spoturno Gonzalez, 5.165.789-6

Nicolás Buero, 5.000.105-4

Universidad de la República
Facultad de Ingeniería

Junio 2026

Índice

1. Introducción

Este informe documenta la resolución de la Tarea 2 del curso *Introducción a la Ciencia de Datos* (edición 2026). La tarea es continuación directa de la Tarea 1 y utiliza el mismo dataset: un subconjunto muestreado del corpus abierto *All the News 2.1 – Component One*, que contiene artículos de noticias publicados en distintos medios de prensa. El objetivo de esta entrega es **construir y evaluar clasificadores automáticos de texto** que identifiquen a qué medio pertenece cada artículo, partiendo de representaciones numéricas del texto.

El trabajo se estructura en dos partes. La Parte 1 cubre la preparación de los datos, la representación numérica del texto mediante *Bag of Words* y TF-IDF, y una exploración visual con PCA. La Parte 2 cubre el entrenamiento, la validación y la comparación de modelos de clasificación.

El código que genera los resultados está en el notebook `Tarea_2/2026_tarea2.ipynb` del repositorio público <https://github.com/Nicolasvb23/intro-cd>.

2. Parte 1: Dataset y representación numérica de texto

2.1. Preparación del dataset

Limpieza previa

El dataset de partida es el mismo que en la Tarea 1: 30.213 artículos distribuidos en 26 medios de prensa. Antes de filtrar por medio de prensa, se aplicaron cuatro correcciones sobre problemas de calidad identificados en la Tarea 1:

1. **Valores placeholder en title:** la columna `title` figura como `non-null` en el `DataFrame` de pandas (no tiene `NaN`), pero en la práctica algunas filas contienen cadenas sin información real, como "Not found", "[Not Found]", "N/A" o guiones repetidos. Estos valores no se capturan con un simple `isnull()`, sino que requieren un chequeo por patrón. Se implementó la función `is_placeholder(val)` basada en una expresión regular que detecta estas cadenas en cualquiera de sus variantes. Los artículos con título placeholder se reportan pero no se eliminan, dado que para la clasificación de esta tarea se usa el cuerpo del artículo, no el título.
2. **Filas con article nulo o placeholder:** 1.176 filas (3,89 % del total) tenían `article` nulo (`NaN`), y adicionalmente algunas contendrían cadenas placeholder. Sin texto que procesar, estas filas no son clasificables y se eliminan.
3. **Filas con publication nula:** 141 filas (0,47 %) no tenían medio de prensa asignado. Como `publication` es la variable objetivo *y* de la clasificación, estas filas no son utilizables y se eliminan.
4. **Duplicados:** se eliminó toda fila cuya combinación (`title`, `article`) apareciera más de una vez. Artículos repetidos que cayeran en ambos conjuntos (train y test) inflarían artificialmente el *accuracy* del modelo.

La Tabla ?? resume el efecto de cada paso de limpieza.

Cuadro 1: Efecto de la limpieza previa sobre el tamaño del dataset.

Paso	Filas eliminadas	Filas restantes
Dataset original	—	30.213
Eliminar <code>publication</code> nula/placeholder	141	30.072
Eliminar <code>article</code> nulo/placeholder	~1.176	~28.896
Eliminar duplicados	[TODO]	[TODO]
Dataset limpio (<code>df_clean</code>)	[TODO] total	[TODO]

Función `clean_text`

Se reutilizó la función `clean_text` desarrollada en la Tarea 1, sin modificaciones. La función aplica los siguientes pasos en orden: eliminación de la primera línea (cabecera repetida), conversión a minúsculas, eliminación de URLs, eliminación de puntuación y caracteres no alfanuméricos (reemplazando por espacio para no pegar palabras), eliminación de números aislados, y normalización de espacios.

A diferencia de lo que se hizo en la Parte 2 de la Tarea 1, aquí **no se eliminan *stopwords* ni identificadores del medio** en la etapa de limpieza: esas decisiones se toman a nivel del vectorizador (`CountVectorizer` o `TfidfVectorizer`) y son parte del análisis de la Sección ??.

Selección de los tres medios principales

El análisis de esta tarea se restringe a los **tres medios con mayor cantidad de artículos** en `df_clean`. Los recuentos se muestran en la Tabla ??.

Cuadro 2: Top 3 medios de prensa por cantidad de artículos en el dataset limpio.

Medio	Artículos	% del total (top 3)
Reuters	~9.280	~62 %
The New York Times	~2.830	~19 %
CNBC	~2.610	~17 %
Total top 3	~14.720	100 %

Los tres medios coinciden con los tres primeros del top 5 de la Tarea 1. El dataset resultante presenta un **desbalance pronunciado**: *Reuters* acumula cerca del 62 % de los artículos, frente al 19 % de *NYT* y el 17 % de *CNBC*. Esto tiene implicancias sobre las métricas de evaluación que se discuten en la Parte 2.

Partición `train/test`

El dataset de los tres medios se dividió en un conjunto de **entrenamiento (70 %)** y un conjunto de **test (30 %)**, utilizando muestreo estratificado por medio de prensa (`stratify=y`).

La estratificación garantiza que la proporción de artículos de cada medio sea la misma en ambos conjuntos. Se fijó `random_state=42` para reproducibilidad.

2.2. Verificación del balance de clases




Figura 1: Proporción de artículos de cada medio en los conjuntos de entrenamiento (izquierda) y test (derecha). La estratificación garantiza distribuciones idénticas en ambos conjuntos.

La Figura ?? confirma que las proporciones son idénticas en train y test, como se espera de un split estratificado. El desbalance del dataset se preserva de forma exacta: aproximadamente 62% de los artículos corresponden a *Reuters*, lo que implica que un clasificador trivial que siempre prediga “Reuters” alcanzaría un *accuracy* de ese orden sin aprender nada del contenido. Este punto se retoma en la Parte 2 al discutir las limitaciones del *accuracy* como única métrica.

2.3. Representación Bag of Words

Cómo funciona

La representación *Bag of Words* (BoW) convierte cada documento en un vector numérico de la siguiente manera: se construye un **vocabulario** fijo con todas las palabras distintas que aparecen en el corpus de entrenamiento, y cada documento se representa como un vector de tamaño igual al vocabulario donde la posición j contiene la **cantidad de veces** que la palabra j aparece en ese documento. El orden de las palabras dentro del texto se ignora completamente.

Tamaño de la matriz

Se ajustó un `CountVectorizer` con parámetros por defecto sobre el conjunto de entrenamiento. La matriz resultante tiene dimensiones $[n_docs \times n_palabras]$, donde:

- **Filas:** la cantidad de artículos en el conjunto de entrenamiento (`[TODO]` artículos).
- **Columnas:** el tamaño del vocabulario aprendido sobre el train (`[TODO]` palabras distintas).

Por qué es una matriz *sparse*

Si se almacenara como una matriz densa (todos los valores en memoria), la matriz BoW ocuparía aproximadamente:

$$[TODO] \times [TODO] \times 8 \text{ bytes} \approx [TODO] \text{ MB}$$

Esto sería inmanejable incluso con este dataset reducido. Sin embargo, la gran mayoría de las entradas son cero: la densidad de la matriz es del orden del 0,2%—0,4%, lo que significa que más del 99% de sus valores son cero. Ninguna nota usa más de unos cientos de palabras distintas, mientras que el vocabulario total tiene decenas de miles. Las matrices *sparse* almacenan únicamente los valores no-nulos y sus posiciones (formato CSR), lo que reduce el uso de memoria en varios órdenes de magnitud.

Si en lugar de 14.000 artículos tuviéramos el dataset completo de 1,8 millones de artículos del corpus original y un vocabulario de cientos de miles de palabras, la matriz densa sería completamente inviable en cualquier equipo de cómputo estándar.

2.4. Representación TF-IDF

Qué es un n-grama

Un **n-grama** es una secuencia contigua de n tokens (palabras o caracteres). Un unigrama ($n = 1$) es una palabra individual; un bigrama ($n = 2$) es un par de palabras consecutivas. Por ejemplo, a partir del texto “*the new york times*” se extraen los bigramas “*the new*”, “*new york*” y “*york times*”. Incluir bigramas en el vocabulario permite capturar expresiones compuestas y contexto local que los unigramas no pueden representar. El parámetro `ngram_range=(1,2)` en el vectorizador combina unigramas y bigramas en el mismo vocabulario, aunque a costa de aumentar dramáticamente el número de columnas.

La transformación TF-IDF

El principal problema de BoW es que las palabras muy frecuentes en todo el corpus (artículos, preposiciones, conjunciones) dominan los vectores aunque no aporten información discriminante entre medios. TF-IDF (*Term Frequency – Inverse Document Frequency*) corrige esto ponderando cada conteo por la siguiente expresión:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t)$$

donde $\text{TF}(t, d)$ es la frecuencia normalizada del término t en el documento d , e $\text{IDF}(t) = \log\left(\frac{N+1}{n_t+1}\right) + 1$ con N el número total de documentos y n_t la cantidad de documentos que contienen t . La transformación tiene dos efectos:

- **Penaliza términos ubicuos:** una palabra que aparece en todos o casi todos los documentos tiene $\text{IDF} \approx 0$, por lo que su peso TF-IDF cae a cero o próximo a cero, independientemente de cuántas veces aparezca en un documento dado.
- **Premia términos discriminantes:** una palabra rara que aparece mucho en un documento particular y poco en el resto recibe un peso alto.

El vectorizador `TfidfVectorizer` se ajusta únicamente sobre el conjunto de entrenamiento (`fit_transform`). El vocabulario y los valores IDF aprendidos se aplican luego sobre el conjunto de test (`transform`), sin recalcularse nada sobre el test. Esto simula correctamente el escenario real donde el modelo no tiene acceso a los datos de evaluación al momento de entrenarse.

2.5. Visualización PCA sobre TF-IDF

Consideraciones de implementación

El análisis de componentes principales (PCA) requiere materializar la matriz como densa para poder centrarla. Con un vocabulario de decenas de miles de palabras y miles de documentos, eso implicaría varios gigabytes en memoria. Por este motivo se utilizó `TruncatedSVD` de `scikit-learn`, que computa las componentes principales directamente sobre la representación *sparse* sin densificarla. El resultado es matemáticamente equivalente al PCA para estos efectos.

Resultados con la configuración base




Figura 2: Mapa PCA (2 primeras componentes) sobre TF-IDF base, coloreado por medio de prensa.

La Figura ?? muestra el conjunto de entrenamiento proyectado sobre las dos primeras componentes principales. Se observa que *Reuters* forma una nube claramente separada del resto, especialmente a lo largo de la primera componente. Esto es esperable dado que *Reuters* tiene pistas léxicas muy marcadas que se discuten más adelante. *NYT* y *CNBC* presentan mayor superposición entre sí, aunque con cierta separación.

Las dos primeras componentes explican solo [TODO] % de la varianza total, lo que indica que **no es posible separar los tres medios de forma perfecta con únicamente 2 componentes**. Los vectores TF-IDF viven en un espacio de alta dimensionalidad y la proyección bidimensional pierde la mayoría de la información.

Comparación de configuraciones




Figura 3: PCA con cuatro configuraciones distintas del `TfidfVectorizer`: base, con *stop words*, sin IDF y con bigramas.

La Figura ?? compara las cuatro configuraciones pedidas. Las observaciones principales son:

a) Filtrado de *stop words* (`stop_words='english'`). Al eliminar las palabras funcionales del inglés (artículos, preposiciones, conjunciones), el vocabulario se reduce y los vectores quedan dominados por términos de contenido. La separación entre medios tiende a mejorar levemente porque se eliminan dimensiones que son equidistribuidas entre todos los documentos y no aportan discriminación. La varianza explicada por las primeras dos componentes suele aumentar respecto a la configuración base.

b) Sin IDF (`use_idf=False`). Con IDF desactivado, los vectores contienen directamente la frecuencia relativa del término en el documento (TF puro). Las palabras muy comunes recuperan el peso que IDF les quitaba. La separación entre medios se deteriora notablemente porque los términos ubicuos vuelven a dominar las componentes principales, reduciendo la varianza explicada en las primeras componentes y comprimiendo los puntos en un espacio más denso y menos separable.

c) Bigramas (`ngram_range=(1,2)`). Al agregar bigramas el vocabulario se expande varios veces (incluye ahora todas las secuencias de dos palabras consecutivas). Los vectores resultantes capturan más contexto local. La separación en el PCA puede mejorar o mantenerse similar a la base, pero el costo computacional aumenta considerablemente. Patrones como *“reuters reporting”* o *“new york”* pasan a ser features explícitas.

Varianza explicada




Figura 4: Varianza explicada por cada componente principal (izquierda) y varianza acumulada (derecha) para los primeros 10 componentes sobre la configuración TF-IDF base.

La Figura ?? muestra que la varianza explicada decrece rápidamente con el número de componentes y que incluso con 10 componentes la varianza acumulada es relativamente baja. Esto refleja la **alta dimensionalidad intrínseca del texto**: la información está repartida entre miles de términos, y ninguna dirección captura una fracción grande de la varianza total.

Origen de la separación observada

La separación en el PCA puede deberse a tres fuentes distintas, que no son mutuamente excluyentes:

- **Pistas explícitas del medio:** como se documentó en la Tarea 1, *Reuters* tiene el dateline (*Reuters*) en el 92 % de sus artículos, y *The Hill* tenía el footer *Capitol Hill Publishing Corp.* en el 99 %. Aunque en esta tarea *The Hill* ya no está presente en el top 3, *Reuters* sigue teniendo estas marcas, lo que crea un eje claro de separación en las primeras componentes. Con la configuración base (sin remoción de boilerplate), la separación de *Reuters* está en gran medida impulsada por estos patrones.
- **Diferencias temáticas:** los tres medios cubren agendas distintas. *Reuters* es una agencia de noticias generalista con fuerte cobertura financiera y de mercados; *CNBC* se especializa en economía y negocios; *NYT* tiene una cobertura amplia que incluye política, cultura y opinión. Estas diferencias de cobertura generan vocabularios característicos que contribuyen a la separación incluso después de remover las pistas directas.
- **Diferencias de estilo editorial:** independientemente del tema, cada medio tiene convenciones propias de escritura (largo de las notas, uso de citas, estructura de los párrafos, vocabulario técnico). Estas diferencias son más sutiles y podrían quedar capturadas en componentes de orden superior, no necesariamente en las primeras dos.

En la configuración base, la primera componente está muy probablemente dominada por las pistas explícitas de *Reuters*. El filtrado de *stop words* no elimina esas pistas; sí lo haría remover el boilerplate mediante regex (como se hizo en la Parte 2 de la Tarea 1), pero ese procesamiento no es parte del análisis de esta sección.